

Primjena NLP za korisničko iskustvo i sigurnost dating aplikacija

Članovi tima:

Nedim Džajić

Amar Grizović

Matej Marinčić

Amina Velić

Tarik Velić

Sarajevo, april 2026.

PREGLED TEME

Savremeno tržište aplikacija za upoznavanje (dating apps), predvođeno platformama poput Tindera, suočava se s izazovima zasićenja korisnika, sigurnosnih rizika i niske stope konverzije iz matcheva u stvaran razgovor. Ovaj dokument predlaže integraciju pet specifičnih NLP rješenja koja transformišu pasivno pretraživanje profila u interaktivno i sigurno iskustvo. Fokus je na korištenju naprednih algoritama za analizu teksta kako bi se personalizovao sadržaj, zaštitili korisnici od zloupotrebe i automatizovala podrška, čime se direktno povećava lojalnost korisnika i profitabilnost kompanije.

POSLOVNI CILJEVI

- 1. Povećanje angažmana: Olakšavanje započinjanja razgovora kroz personalizovane sugestije.
- 2. Unapređenje sigurnosti: Automatizirana detekcija govora mržnje i pokušaja prevara u realnom vremenu.
- 3. Personalizacija: Kvalitetnije spajanje korisnika na osnovu analize semantičke sličnosti njihovih interesovanja.
- 4. Proaktivno upravljanje korisničkim iskustvom: Identifikacija pada interesovanja u razgovoru i automatizovana podrška korisnicima koji iskazuju frustraciju ili nelagodu prije nego što napuste aplikaciju.

SPECIFIKACIJA

Svaki član tima zadužen je za jedan od sljedećih zadataka:

NLP Task	Opis rješenja	Poslovna korist
Sistem za preporučivanje	Analiza "bio" sekcije profila pomoću word embedding-a za pronalaženje semantičke sličnosti.	Veći broj uspješnih spajanja i duže zadržavanje u aplikaciji.
Identifikacija govora mržnje	Automatsko skeniranje poruka radi detekcije uvreda i uznemiravanja.	Smanjenje troškova moderacije i zaštita reputacije brenda.
Modeliranje tema (Icebreakers)	Ekstrakcija ključnih tema iz profila oba korisnika radi generisanja prijedloga za	Smanjenje broja neaktivnih "match-eva".

NLP Task	Opis rješenja	Poslovna korist
	prvu poruku.	
Detekcija prevara (Bot detection)	Prepoznavanje obrazaca ponašanja i teksta specifičnih za lažne profile i scam-ere.	Veće povjerenje korisnika u sigurnost platforme.
Dinamička analiza sentimenta i emocija	Analiza toka razgovora u realnom vremenu i recenzija. Detekcija emocionalnih stanja (frustracija, sarkazam, nezadovoljstvo) i aspekata usluge.	Smanjenje stope odustajanja i sprečavanje eskalacije konflikata među korisnicima.

PLAN RADA

- Prikupljanje i preprocesiranje podataka**
 - Prikupljanje relevantnih datasetova (OkCupid, SMS Spam)
 - Čišćenje teksta (uklanjanje stop-words, tokenizacija)
- Razvoj i treniranje modela**
 - Implementacija individualnih NLP zadataka.
 - Evaluacija preciznosti (Accuracy, F1-score)
- Sumarna analiza postignutih ciljeva**
 - Analiza rezultata po taskovima
 - Komparacija i ocjena primjenjivosti rješenja
- Finalizacija izvještaja i prezentacija**
 - Dokumentovanje rezultata i poslovnih benefita.